

『日本語話し言葉コーパス』の概観

Version. 1.2

前川喜久雄（国立国語研究所）

目 次

1. 『日本語話し言葉コーパス』	1
2. CSJ に収録された音声	2
2. 1 学会講演と模擬講演	3
2. 2 その他	4
2. 3 朗読	4
2. 4 再朗読	5
2. 5 対話	5
2. 6 再朗読および対話の収録についての補遺	5
2. 7 話者の分布	5
2. 8 ファイルの命名	8
3. 研究用付加情報（アノテーション）	9
4. 音声の自発性	11
4. 1 自然の序列	11
4. 2 印象評定	11
4. 3 音声収録記録票とアンケート	12
5. XML 文書	12
6. 言語モデルと音響モデル	12
7. 話者の個人情報	12
8. 予備的解析結果の所在	13
謝辞	13
文献	13
付録 1 再朗読および対話における話者とファイル名の対応	15
付録 2 音声認識研究用テストセットの構成	16
付録 3 主要なファイルの配置とファイル名拡張子	17

1. 『日本語話し言葉コーパス』

『日本語話し言葉コーパス』(Corpus of Spontaneous Japanese:以下CSJと略称する)は、現代日本語の自発音声を種々の研究用付加情報とともに大量に格納したデータベースであり、語数にして約 750 万語、時間にして 660 時間の音声が含まれている。CSJ は、1) 多数の話者による多少とも自発的な音声を対象としていること、2) 豊富な研究用付加情報を提供していること、3) 発話スタイルないし自発性に対する評価を与えていること、4) XML 文書化されたデータも公開していることなど、従来の音声データベースにはない多くの特長を有している。

CSJ は国立国語研究所と通信総合研究所によって開発された。開発資金は、東京工業大学の古井貞熙教授を総括責任者とする文科省科学技術振興調製費開放的融合研究制度課題「話し言葉の言語的・パラ言

語的構造の解明に基づく『話し言葉工学』の構築(1999-2003)に拠った。古井教授にプロジェクト全般にわたるご指導をいただいたほか、ATR 音声言語コミュニケーション研究所、NTT コミュニケーション科学基礎研究所、京都大学等の研究者にも、多岐にわたるご協力をいただいた。

以下、本文書では CSJ の概要をできるだけ簡潔に説明する。本文書はあくまで概説であり、CSJ の利用に必要なすべての情報を網羅しているわけではない。CSJ に含まれる多様な研究用情報やツール類については、表 1 に示す解説文書が用意されているので、これらの文書を参照していただく必要がある。これらの文書は本文書と同じ場所(Disk1の/DOC ディレクトリ)に格納されている。

表1 『日本語話し言葉コーパス』の解説文書

文書名	ファイル名
『日本語話し言葉コーパス』の概観*	overview.pdf
音声収録作業の概要	recording.pdf
記録票データ・対話記録票データ・講演者属性データ・対話参加講演者の講演一覧の解説	data_attribute.pdf
転記テキストの仕様*	transcription.pdf
文節の仕様について*	bunsetsu.pdf
『日本語話し言葉コーパス』の形態論情報の概要*	pos.pdf
短単位・長単位データマニュアル*	wdb.pdf
短単位辞書マニュアル	suwdic.pdf
『日本語話し言葉コーパス』の分節音ラベリング*	segment.pdf
『日本語話し言葉コーパス』のイントネーションラベリング*	intonation.pdf
印象評定データの概要	impression.pdf
『日本語話し言葉コーパス』における節単位認定*	clause.pdf
『日本語話し言葉コーパス』における係り受け構造付与	dependency.pdf
『日本語話し言葉コーパス』における自由要約・重要文抽出データについて	summarydata.pdf
『日本語話し言葉コーパス』の談話境界情報について	discourse.pdf
音声認識のための音響モデルと言語モデルの仕様	asr.pdf
『日本語話し言葉コーパス』XML 文書について*	xml.pdf
『日本語話し言葉コーパス』における文編集データについて	revision_data.pdf
『日本語話し言葉コーパス』節単位 XML 文書について	cuxml.pdf
『日本語話し言葉コーパス』節単位 XML ビューワーの使用法	cuxml_viewer.pdf
『日本語話し言葉コーパスの構築法』(国立国語研究所報告書 124)	kokken124.pdf

* 『日本語話し言葉コーパスの構築法』(kokken124.pdf)も参照のこと。

2. CSJ に収録された音声

CSJ はその名が示すように自発音声を対象としたデータベースである。しかし、ひとことに自発音声と言ってもその内容はきわめて多様であり、自発音声の全体像を一気に把握するようなデータベースを構築することは実際上不可能と考えられる。そこで、自発音声データベースを設計するにあたっては、対象とする音声の性格をあらかじめある程度限定しておく必要がある。

CSJ の設計では、CSJ を自発音声の自動音声認識の研究リソースとして活用することを想定して、以下の性格をもった音声を主要な対象とした。

- 1) まとまった内容をもつ(すなわち雑談ではない)
- 2) 全国共通語の(すなわち語彙と文法に方言的特徴のない)
- 3) 独話(モノローグ) 音声

表2はCSJに含まれる音声を分類して、以下に説明するタイプ毎に、話者数、ファイル数(講演数)、総時間数を示している。表2から学会講演と模擬講演という2種類の独話音声時間が時間にしてCSJの約90%を占めていることがわかる。これらの音声タイプについては2.1以下で説明をくわえる。

表2 音声のタイプと時間

音声のタイプ	タイプ	話者数(異なり)	ファイル数	時間
学会講演	独話	819	987	274.4
模擬講演	独話	** 594	1,715	329.9
その他	独話	*** 16	19	24.1
学会講演インタビュー	対話	* (10)	10	2.1
模擬講演インタビュー	対話	* (16)	16	3.4
課題指向対話	対話	* (16)	16	3.1
自由対話	対話	* (16)	16	3.6
再朗読	朗読	* (16)	16	5.5
朗読	朗読	* (248)	507	15.5
計		1,417	3,302	661.6

* ()内は全員が学会講演話者もしくは模擬講演話者としてカウントされている

** 10名は学会講演話者としてもカウントされている

*** 2名は学会講演話者としてもカウントされている

表3はCSJに含まれる形態論的単位数(語数)を音声のタイプごとに示している。CSJでは短単位、長単位という2種類の形態論的単位を用いているので(pos.pdf参照)、それぞれの数字を示した。言い誤りによって生じた語の断片などは除外されている。CSJ全体での短単位総数は7,525,125であり、設計上の目標値(700万語、3節参照)を大幅に超過している。

表の最終列は短単位数に占める長単位数の百分率である。この率は、学会講演で最低値をとり、模擬講演と対話で最大値をとっている。これは学会講演には専門語が多く用いられるために相対的に多くの複合語(複合辞)が含まれていることによると考えられる。この例が示唆するように、CSJに格納されている音声は--上記1-3)の制約にはしたがいつつも--多様性に富んでいる。以下、各タイプについて簡単に説明する。

表3 形態論的単位数

音声のタイプ	短単位数	長単位数	%長単位
学会講演	3,279,364	2,654,823	81.0
模擬講演	3,605,729	3,115,302	86.4
その他	282,728	239,989	84.9
朗読と再朗読	207,478	172,216	83.0
対話	149,826	131,544	87.8
全体	7,525,125	6,313,874	83.9

2. 1 学会講演と模擬講演

学会講演(Academic Presentation Speech: APS)は、理工学、人文、社会の3領域におよぶ種々の学会における研究発表のライブ録音である。講演時間は10分から25分程度が大半であるが、1時間前後に及ぶ特別講演の類も少数含まれている。学会講演の多くをしめる理工学系の学会では、男性の大学院生であることが多いので、学会講演の話者は、年齢と性別の偏りがある。発話スタイルは概してあらたまり度が高い(4節参

照)。

模擬講演(Simulated Public Speaking: SPS)は、できるだけ年齢と性別のバランスをとった一般話者による、日常的話題についての講演である。話者の大部分は人材派遣会社からの派遣であり、あらかじめ指定された3種の一般的テーマ(例えば「人生で一番嬉しかったこと」「人生で一番悲しかったこと」「私の住んでいる街」等)に基づいて、具体的な講演内容を決めてタイトルをつけ、1講演10～15分程度のスピーチをおこなった。発話スタイルは概して学会講演よりもくだけたものとなっている(4節参照)。

2. 2 その他

学会講演にも模擬講演にも該当しない独話音声は、「その他」に分類されている。具体的には、以下のものである。

- 研究機関が一般聴衆を対象に企画した連続講演会の講演音声。対象は歴史や民俗学など。
- 国語研究所が一般聴衆むけに開催した講演会の講演音声、および国語研究所員を聴衆とした識者による講演。後者は1講演のみである。
- 専門学校における日本語教師養成関係の講義音声

その他に分類した音声は、独話である点では学会講演や模擬講演と同一であるが、話者と聴き手の関係が専門家と一般聴衆の関係である点において、学会講演とも模擬講演とも異なっている。

2. 3 朗読

CSJ の大部分を占める学会講演と模擬講演は自発的な独話(モノローグ)音声である。しかし、独話音声だけでは、自発音声の限定された一面しか検討することができない。また、自発音声の特徴を把握するためには、朗読された音声との比較も必要である。そこで、独話との対照用に、対話と朗読の音声も収録した。

朗読には、「朗読音声」と「再朗読音声」の二種類がある。「朗読音声」は模擬講演話者の一部が、書き言葉のテキストを朗読したものである。テキストとしては、野本陽代著「宇宙の果てにせまる」(岩波新書新赤版 570,1988)および中村桂子著『あなたのなかのDNA』(ハヤカワノンフィクション文庫 176,1994),p.9-10)の一節を利用させていただいた。以下にその一部を示す。このうち『あなたのなかのDNA』は、会話体の書き言葉であり、その話し手としては女性が想定されているため、男性話者による朗読では、性差にかかわる終助詞を一箇所修正して朗読に供している(朗読テキストの詳細については recording.pdf 参照)。

私たちの住んでいる宇宙は、いったいどこまで広がっているのだろうか。いつ生まれて、いつまで存在するのだろうか。そこには、どんな天体があって、それらは将来どうなるのだろうか。

(『宇宙の果てにせまる』)

となりの家のかな子ちゃんは女子大生。好奇心にあふれた、元気な女の子です。彼女がある日、聞きました。

—「先生、DNAって何ですか？」

ん？

—「DNAって、ほら、遺伝子なんですよ。」

(『あなたのなかのDNA』)

上記2種類の他、さらに3種類のテキストを用いた朗読音声を収録しており CSJ にも格納しているが、これらを朗読した話者はそれぞれ4名のみである(recording.pdf 参照)。

2. 4 再朗読

再朗読音声とは、学会講演ないし模擬講演として収録された音声の転記テキストを同一の話者が朗読した音声である。フィラーや言い直しも朗読の対象としている。再朗読の話者は、学会講演話者から選ばれた 10 名と、模擬講演話者から選ばれた 6 名の合計 16 名である。これらの話者は次に述べる対話音声の話者でもある。詳しくは 2.6 参照。

2. 5 対話

対話音声には「学会講演インタビュー」「模擬講演インタビュー」「課題指向対話」「自由対話」の 4 種類がある。2 種類のインタビューは、上記 16 名による学会講演ないし模擬講演 (10 名は両方、6 名は模擬講演のみ) に関してインタビュワーが様々な質問を発し、講演者がこれに答える形式の対話である。予想されるように、発話の大半は、質問に対する回答によって占められている。

インタビュワーは 20 代と 30 代の女性各 1 名である。インタビュワーは、学会講演インタビューに関しては事前に予稿集論文に目を通したうえで、また、インタビュー対象の模擬講演については、その講演の収録現場で講演を聴取したうえで、インタビューに臨んでいる。

課題指向対話では、インタビューとの対比のため、参加者 2 名 (上記インタビューと同一ペア) の発話量が等しくなりやすい課題を選定した。具体的には、実在の芸能人に講演を依頼した場合の謝礼 (ギャラ) の額を想像し、その多寡の順に、芸能人 9 ないし 10 名をソートするタスク (ギャラ・タスク) を考案した。対話開始時点で各話者に手渡されている人名リストは、わざと一致しないように作成してあるので、謝礼額の推定に先立って (あるいは同時に)、推定対象となる芸能人の完全なリストを作成するための対話も必要とされる。

最後に自由対話では、話題の制約なしに、10 分程度、自由に対話をおこなってもらっている。以上、4 種類の対話音声は、同一の話者ペア (講演者とインタビュアー) によって発話されている。

2. 6 再朗読および対話の収録についての補遺

先に触れたように、再朗読および対話の話者は、10 名が学会講演の経験者から、6 名が模擬講演の経験者から選ばれている。このうち学会講演経験者の大部分は CSJ の関係者かその知人である。

CSJ に格納された各音声タイプ間には自発性の程度差が存在していると考えられるが (4 節参照)、これら 16 名の話者については、自発性が最も低いと考えられる再朗読音声から、自発性が最も高いと考えられる対話音声まで、自発性の幅広い領域にまたがる音声の比較が可能である。

話者 16 名の講演者 ID と音声ファイル名の対応表を本文書末に付録 1 として掲載する。この表中の模擬講演 (「模擬」) は、学会講演経験者のみならず、模擬講演経験者 6 名についても新規に収録したものであることに注意してほしい。これによって模擬講演のテーマは統一が保たれている。

2. 7 話者の分布

自発音声の多様性の一部は、性別、出生地、居住歴、学歴、講演経験の有無など、話者の社会的属性に起因していると考えられる。そのため、自発音声の研究では話者の属性への配慮が欠かせない。CSJ では、話者のプライバシーを侵害しないと判断された範囲で話者の属性情報を公開している (属性情報の詳細については recording.pdf および data_attribute.pdf 参照)。ここでは、最も代表的な属性として、話者の生年代と性別と出生地の分布を概観する。

まず、図 1, 2 に学会講演と模擬講演における話者の生年代の分布を示した。CSJ のデータでは、話者の生

年を西暦で5年刻みに区分して公開しているが、図1,2ではこれを10年ごとに区分しなおして集計した。

図1は生年代ごとの延べ話者数、図2は同じく異なり話者数の分布を示している。延べと異なりの区別が必要となるのは、模擬講演だけでなく、学会講演においても同一話者の音声が複数回収録されていることがあるからである。これを重複してカウントしたのが延べ話者数、何回講演しても1名としてカウントしたのが異なり話者数である。

図1においても図2においても、学会講演話者数は生年代が下がるにつれ単調に増加している。一方、模擬講演話者は、学会講演に較べれば相対的にバランスのとれた分布を示している。なお、学会講演話者のうち9名については生年が不明であるために集計から除外している。




図1 学会講演と模擬講演話者の生年による分布(延べ)




図2 学会講演と模擬講演話者の生年による分布(異なり)

次に、表4、5に話者の性別と音声タイプのカロス集計を示す。表4が延べ話者数、表5が異なり話者数である。表5では学会講演から対話までの合計が「全体」欄の数字と一致していない。これは同一話者が複数の音

声タイプの講演を行っている場合に重複してカウントしているためであり(同一タイプ内部での重複はカウントしていない)、再朗読と対話の話者を学会講演ないし模擬講演の話者から選択していることと「その他」の話者のうち2名が学会講演話者でもあることが、その原因である。

学会講演話者の大多数は男性である。これは学会発表の多くが大学院生によっておこなわれており、その大部分が男性であることによる。この傾向は特に理工系大学院において著しい(ちなみに図1,2の学会講演において 70 年代生まれの話者数が突出しているのも大学院生の多さによる)。一方、模擬講演以下では、男女がほぼ均等に分布している。

表4 話者の性別の分布(延べ)

性別	学会講演	模擬講演	その他	朗読	再朗読	対話	全体
女	173	910	9	252	8	29	1381
男	814	805	10	255	8	29	1921
計	987	1715	19	507	16	58	3302

表5 話者の性別の分布(異なり)

性別	学会講演	模擬講演	その他	朗読	再朗読および対話	全体
女	138	*331	6	(122)	(8)	****470
男	681	**263	***10	(124)	(8)	947
計	819	594	16	(246)	(16)	1417

()内の数字は学会講演もしくは模擬講演と重複、* 5 名が学会講演と重複、** 5 名が学会講演と重複

*** 2 名が学会講演と重複、**** インタビュワーを加えると 471 名




図3 話者の出生地の分布(延べ)




図4 話者の出生地の分布(異なり)

図3、4に話者の出生地による分布を示す。図3が延べ話者数、図4が異なり話者数である。いずれの図においても「東京」「首都圏」「それ以外」に分類し百分率で示している。「首都圏」とは千葉、埼玉、神奈川の3県をさす。なお、ここで、出生地とは文字通り話者が生まれた土地であって生育地ではない。社会言語学的な研究などにおいてさらに詳しい履歴が必要とされる場合は、CSJ の講演者属性データ(Disk1 /DATA の speaker_data.dat)に転居歴のデータが含まれているので、それを利用できる(data_attribute.pdf 参照)。

2. 8 ファイルの命名

CSJ のファイル名(本体部分)には、以下の規則に則って音声タイプとその内訳、さらに話者の性別が反映されている(recording.pdfも参照)。

- ファイル名先頭のアルファベット1文字は音声のタイプを示す
 - A:学会講演
 - S:模擬講演
 - M:その他
 - D:対話音声
 - R:朗読(含再朗読)音声
- 続く2桁の数字は、音声タイプ毎に、その内訳を示す
 - A では学会の別
 - S では講演テーマの別
 - D では対話の種類(インタビュー2種、課題指向、自由)
 - R では朗読テキストの別
- 続くアルファベット1文字は、話者の性別を示す
 - F:女性
 - M:男性
- 残る4桁の数字は各音声タイプ内での識別番号

3. 研究用付加情報（アノテーション）

CSJ には豊富な研究用情報（アノテーション）が付加されている。ただし、アノテーションは全体に対して齊一的に実施されていないことに注意が必要である。CSJのうち、「コア」と呼ばれる約50万語分については、特に多くの情報を集中的に付与した。図5はコアとそれ以外における情報付与の異同の概念図、表6はコアにおけるファイルの分布を音声タイプと話者の性別に関する内訳である。CSJ関連の論文ではコアという語が必ずしも一様に用いられていないが、以下では、分節音ラベルとイントネーションラベルが付与されている範囲をコアと呼ぶことにする。




図5 CSJのアノテーションにおける階層構造

表6 コアの内訳

音声のタイプ	女性話者	男性話者	計
学会講演	24	46	70
模擬講演	54	53	107
対話	9	9	18
朗読	3	3	6
計	90	111	201

CSJ に、このような階層構造を導入した理由は以下の通りである。「話し言葉工学」プロジェクトの目標は、自然な話し言葉（自発音声）の音声言語処理技術のための基盤技術の開拓であった。工学領域における研究としては、1) 自発音声の自動認識、2) 自発音声認識結果の自動要約、3) 話し言葉の自動形態素解析、等を想定しており、これらに加えて、4) 自発音声の韻律特徴、5) 自発音声における音声変異、6) 自発音声の統語的、談話的構造と韻律特徴の関係、7) 講演音声聴き手に与える印象、等の言語学的ないし音声学的研究における利用も、念頭においた。

CSJ の設計にあたって問題となったのが、音声認識研究（上記の1と2）とそれ以外の関係である。統計的学習に基礎をおく音声認識研究においてはデータの量が重視されるのに対して、自然言語解析や言語研究

においては、量よりもむしろ多様かつ精密なアノテーション情報を提供することが大切と考えられた。そこで、コアを設定し、そこにアノテーションを集中することにした。

まず、音声認識研究に最低限必要なデータ量を 700 万語(短単位)と推定し、これをデータベース全体のサイズの目標値とした。この 700 万語分(実際の CSJ では表3に示したように約 752 万語)に対しては、音声信号(16bit, 16kHz)の他に、精密な転記テキスト、形態論情報(品詞情報)、節単位情報を提供して、音声認識研究での利便性を確保した。一方、コアに対しては、上記の情報に加えて以下の付加情報を追加することによって、言語研究等における利便性を追求した。1) 分節音ラベル、2) イントネーションラベル、3) 節単位情報、4) 係り受け情報、5) 要約・重要文情報。さらに、コアに含まれる模擬講演の一部、40 ファイルに対しては、6) 談話境界ラベルも付与した。これらの付加情報の仕様については、表 1 に示した解説文書に詳しい。

以上のほかにも、コアとコア以外の関係について指摘しておくべきことがある。

- コアのサイズは、5年間という研究実施期間において実現可能な上限として推定した。また、コアに含まれる音声は、東京ないし首都圏で出生した話者のものとした。これはイントネーションラベリング方式が東京方言のアクセント体系に依存しているからである。
- 形態論情報もコアに関連した異同がある。CSJ のうちコアを含む約 100 万短単位分の形態論情報は人手で実施されており、精度が高い(ランダムサンプリングによる推定では 99.9%)。一方、残る 650 万短単位分はコンピュータにより自動解析されたものを、時間が許す範囲で人手修正したものであり、その精度は 97～98%と推定される。また、人手による解析結果と自動解析結果とでは、用言の活用型と活用形の分類が一部相違しているので注意が必要である(wdb.pdf参照)。
- 節単位情報にも上と類似の相違がある。コアの節単位情報は自動解析結果を人手で修正しているが、コア以外に関しては自動解析結果をそのまま提供している。
- 節単位情報(手作業)、係り受け情報、要約・重要文情報は、コアに含まれる独話と下に説明する「テストセット」だけを対象としている。
- 印象評定(集合評定)データは、コアの独話(学会講演ないし模擬講演)を対象として実際にしているが、若干の例外がある。すなわち S02F0852 はコアの模擬公園であるが、印象評定の対象外となっており、A01M0035 はコア以外の学会講演であるが、印象評定の対象となっている。
- 談話境界情報は、コアの独話のうち 40 講演(学会講演ないし模擬講演)にだけ付与されている。
- CSJ を音声認識研究で利用する過程で、認識システムの性能を客観的に評価するための「テストセット」30 ファイルを選定し利用した。このテストセットにはコア以外のファイルが 22 ファイル含まれている。この22ファイルには節単位情報(手作業)、係り受け情報、要約・重要文情報が付与されている(談話境界情報は付与されていない)。テストセットに含まれるファイルのリストを本文書末に付録2として掲載した。

このように、CSJには大きくは、コア、コアを含む 100 万語、それ以外の三階層があり、またコア内部にも付加情報の濃淡がある。CSJに格納された 3302 個の音声ファイルのそれぞれにどのような研究用情報が与えられているかは、Disk1 の/DATA ディレクトリにある talk_data.dat というデータファイルに記載されている。

CSJは「自発」音声データベースである。しかし、音声ないし言語の自発性という概念を明確化することは、実は簡単でない。自発性について用いられる説明のひとつに「発話の時点において、あらかじめ発話の形式が決定されていない発話」というものがある。CSJに収められた音声は、朗読および再朗読音声を除外すれば、総じてこの規定に適う。しかし、2779個におよぶ講演ないし対話音声を比較すると、そこには自発性の程度差が存在していることが明らかである(さらに、CSJの場合、朗読・再朗読音声にもかなりの数のフィラーや語断片が含まれている。これらいわゆる非流暢性が自発音声の特徴であるとすれば、朗読音声にもまた自発性の程度差が存在することになる)。

4. 1 自然の序列

自発性低 ←————→ 自発性高

ただし、このうち学会講演と模擬講演との間の差異については、他のカテゴリ間の差よりも小さい可能性があり、また、量的に CSJ の大部分を占める音声でもあるために、両者間の差異をきわだたせる対策をとった。具体的には、模擬講演話者ができるだけリラックスした状態で録音に臨めるよう、収録に先立って収録スタッフと雑談を交わす時間を設ける、収録中も収録スタッフは積極的にならずき等の反応をかえすといった対策である(学会講演話者には働きかけようがないので、何も対策を施していない)。いずれも素朴な対策であるが、一定の効果を発揮したことは、データの解析によって確認できる。

自然の序列は、しかし、範疇的なものではない。特に学会講演と模擬講演の間では、前節に述べた収録上の対策にも関わらず、序列の逆転が生じていることが少なくないと思われる。そこで、個々の講演についても、その自発性をある程度客観的に評価する手段があるとよい。そのような評価の一助として、CSJ のデータ収録作業では、原則としてすべての講演音声に対して音声収録記録票を作成し、その一部を音声聴き手に及ぼす印象の主観評定に充てた。これを印象評定データと呼ぶ。印象評定項目の一部は自発性の程度差に関する外的指標として利用することができる。

p.11

ただし、単独評価データには、ひとつの講演に評価者が1名だけであること、データベース全体では多数の評価者が参加していること、講演の前半を聴いた時点で評価を行っているため講演中のどの部分が特に印象形成に影響したかが明らかでない場合がありうること等の問題がある。これらの問題を解決するために作成したのが集合評価による印象評価データである。集合評価データは複数の評価者による評価結果であり、評価方法も実験心理学的により厳密な手順を踏んだものとなっている。単独評価データについて上で指摘した問題はほぼ解決されているが、対象となっているのはコアの独話だけである。印象評価データの詳細については data_attribute.pdf(単独評価データ)および impression.pdf(集合評価データ) 参照。

4. 3 音声収録記録票とアンケート

印象評価データの他にも、自発性の評価に利用できるデータがある。ひとつは、音声収録スタッフが音声収録記録票に記入したコメントである。スタッフは、話者が原稿を読み上げていることが明らかな場合には、その旨のコメントを記録票の備考欄に記している。もうひとつ、音声収録に先立って話者に実施したアンケートも自発性の評価に関連した項目を含んでいる。これらの情報は Disk1 の /DOC ディレクトリ中の talk_data.dat というデータファイルに記録されている(data_attribute.pdf 参照)。

5. XML 文書

CSJ に付与された多種多様な研究用情報を一括して表現するために、XML 文書化をおこなった。XML 化は元来、各種データの整合性をチェックするために実施したものであるが、XML 文書は、複雑な情報検索の用途にも向いているので『日本語話し言葉コーパス』の一部として公開することにした。XML 文書の仕様についてはxml.pdf 参照。

6. 言語モデルと音響モデル

CSJ には京都大学と東京工業大学で開発された音声認識用音響モデルと言語モデルが Disk1 の /LM(言語モデル)、/AM(音響モデル)ディレクトリに同梱されている。これらについては asr.pdf 参照。

7. 話者の個人情報

本文書に述べたように CSJ には 1417 名(インタビューを加えると 1418 名)にのぼる話者の音声記録されている。自発音声の研究では話者の個人的属性に関する知識が必要となることが多いと考えられるので、Disk1 の /DATA ディレクトリにおかれた speaker_data.dat というデータファイルに話者の個人情報を記録して公開している(data_attribute.pdf)。

一方、話者から音声の収録とデータ公開の承諾を得るにあたっては、話者の個人情報を不必要に開示しないことを条件としていた。これらの相反する制約を両立させるために、以下の方針に則ることとした。

- 1) 話者の氏名は開示しない。学会講演を収録した学会名も開示しない
- 2) 講演中の話者ないし関係者の個人情報に関する言語情報(自己紹介等)は消去する
- 3) 話者の年齢は5歳刻みで開示する
- 4) 音声信号に含まれる個人性情報はそのまま開示する(音声は加工しない)

収録した音声の中に話者やその関係者の身元を特定できる情報が含まれていた場合には、該当部分の転記テキストを伏せ字とし、あわせて伏せ字を含む転記基本単位全体に対応する音声信号をホワイトノイズで置

換する処理をとった。また、ごく稀にはあるが、いわゆる差別語に属すると判断される表現が用いられている場合も、同様の処理を施している(transcription.pdf のタグ(R)についての記述参照)。

しかし、以上の処理にもかかわらず、CSJ の話者を特定することは不可能ではない。知人の音声であれば、それを聞くことによって個人を同定することができるし、学会講演は、その内容から、学会名を特定することが不可能でない。CSJ の利用許諾に関する覚書に規定されているように、CSJ の利用者がデータを解析することによって知りえた個人情報を開示することは固く禁止されている。

8. 予備的解析結果の所在

CSJ の構築過程では、想定したとおりのデータが採れているかどうかを確認するために、折に触れて予備的解析を実施した。模擬講演は本当に学会講演よりも発話スタイルがぐくんでいるのか、自発音声と朗読音声では発話速度がどの程度異なっているのか、印象評定データと種々の言語変異現象との間には相関が認められるか、等々の検証である。予備的解析結果の一部は、国立国語研究所のホームページで公開しているので参照していただきたい。

<http://www.kokken.go.jp/katsudo/seika/corpus/>

また以下に CSJ の設計に関する文献と予備的解析結果に関する文献のうち比較的に入手が容易なものを挙げておく。

謝辞

『日本語話し言葉コーパス』に音声をご提供いただいた話者の皆様、および、学会講演音声の収録を許可していただいた諸学会に心より感謝いたします。

文献

- Furui, Sadaoki, Manobu Nakamura, Tomohisa Ichiba, and Koji Iwata.. “Analysis and recognition of spontaneous speech using *Corpus of Spontaneous Japanese*.” *Speech Communication*, 47, pp.208-219, 2005
- Maekawa, Kikuo, Hanae Koiso, Sadaoki Furui and Hitoshi Isahara.. “Spontaneous speech corpus of Japanese.” *Proceedings of the Second International Conference of Language Resource and Evaluation*, 2, pp.947-952, 2000.
- Maekawa, Kikuo, Hanae Koiso, Hideaki Kikuchi, and Kiyoko Yoneyama. “Use of a large-scale spontaneous speech corpus in the study of linguistic variation.” *Proceedings of the 15th International Congress of Phonetic Sciences (ICPhS 2003)*, pp. 643-646, 2003.
- Maekawa, Kikuo and Hideaki Kikuchi. “Corpus-based analysis of vowel devoicing in spontaneous Japanese: an interim report,” In J. van de Weijer, K. Nanjo, and T. Nishihara, eds., *Voicing in Japanese*, Mouton de Gruyter, pp.205-228, 2005.
- 小椋秀樹.『日本語話し言葉コーパス』の資料性—形態論情報を用いた分析から—」国語語彙史の研究, 24, 和泉書院, pp.259-275, 2005.
- 籠宮隆之・山住賢司・榎洋一・前川喜久雄.「講演音声の大局的な印象に影響を与える要因」音声研究, 11(2), pp.65-78, 2007.

- 籠宮隆之, 山住賢司, 槇洋一, 前川喜久雄. 「聴取実験に基づく講演音声の印象評定データの構築とその分析」 社会言語科学, 9(2), pp.65-76, 2007.
- 小磯花絵. 「コーパスによる音声談話の研究」 『日本語学』22(4 月臨時増刊号), pp.200-209, 2003.
- 小磯花絵・間淵洋子・前川喜久雄. 「助詞の撥音化現象: 『日本語話し言葉コーパス』を用いた音声転訛現象の分析」 人工知能学会研究会資料, SIG-SLUD-A403-02, pp.7-12, 2006.
- 古井貞熙・前川喜久雄・井佐原均. 「科学技術振興調整費開放的融合研究制度: 大規模コーパスに基づく『話し言葉工学』の構築」 日本音響学会誌, 56 (11), pp.752-755, 2000.
- 前川喜久雄. 「スピーチのデータベースー『日本語話し言葉コーパス』についてー」 日本語学, 20 (6), pp.12-27, 2001.
- 前川喜久雄. 「『日本語話し言葉コーパス』を用いた言語変異研究」 音声研究, 6 (3), pp.48-59, 2002.
- 前川喜久雄. 「『日本語話し言葉コーパス』の概要」, 日本語科学, 15, pp.111-133, 2004.
- 前川喜久雄・五十嵐陽介. 「2 モーラ有核助詞の韻律上の独立性ー『日本語話し言葉コーパス』の分析ー」 音声研究, 10 (2), pp.33-42, 2006.
- 前川喜久雄・籠宮隆之・小磯花絵・小椋秀樹・菊池英明. 「日本語話し言葉コーパスの設計」 音声研究, 4 (2), pp.51-61, 2000.
- 山住賢司・籠宮隆之・槇洋一・前川喜久雄. 「講演音声の印象評価尺度」 日本音響学会誌, 61(6), pp.303-311, 2005.

付録 1 再朗読および対話における話者とファイル名の対応

出自	ID	再朗読	元講演	課題指向	自由	INT 模擬	INT 学会	模擬
学会	8	R00M0132	A01M0074	D02M0016	D03M0048	D01M0005	D04M0041	S05M1506
学会	19	R00F0028	A05F0043	D02F0015	D03F0058	D01F0002	D04F0022	S05F1041
学会	373	R00M0415	A11M0469	D02M0024	D03M0038	D01M0020	D04M0021	S05M1623
学会	423	R00M0187	A01M0056	D02M0028	D03M0017	D01M0019	D04M0056	S05M0613
学会	463	R00F0178	A01F0122	D02F0031	D03F0008	D01F0030	D04F0044	S05F0463
学会	471	R00M0134	A11M0369	D02M0051	D03M0004	D01M0009	D04M0010	S05M1666
学会	514	R00F0407	A06F0128	D02F0025	D03F0006	D01F0023	D04F0050	S05F1600
学会	674	R00F0149	A01F0861	D02F0032	D03F0001	D01F0003	D04F0011	S05F1385
学会	685	R00M0036	A11M0846	D02M0039	D03M0037	D01M0047	D04M0052	S05M1236
学会	1185	R00F0304	A11F0703	D02F0054	D03F0034	D01F0049	D04F0029	S05F0391
模擬	68	R00F0061	S02F0852	D02F0033	D03F0036	D01F0046	—	S05F0378
模擬	251	R00M0286	S01M0998	D02M0035	D03M0053	D01M0043	—	S05M0417
模擬	790	R00M0071	S02M0444	D02M0014	D03M0013	D01M0012	—	S05M1406
模擬	808	R00F0306	S01F0664	D02F0027	D03F0045	D01F0055	—	S05F0899
模擬	910	R00M0019	S01M1401	D02M0026	D03M0007	D01M0042	—	S05M0956
模擬	1125	R00F0287	S03F0737	D02F0018	D03F0040	D01F0057	—	S05F1664

出自：講演者が学会講演経験者か模擬講演経験者かの別

ID：講演者 ID

再朗読：再朗読のファイル名

元講演：再朗読の対象としたオリジナルの学会講演ないし模擬講演ファイル名

課題指向：課題指向対話のファイル名

自由：自由対話のファイル名

INT 模擬：模擬講演（＝模擬）に関するインタビューのファイル名

INT 学会：学会講演（＝元講演）に関するインタビューのファイル名。出自＝学会の話者のみ。

模擬：新規に収録した模擬講演のファイル名（これについてインタビューを実施）

付録2 音声認識研究用テストセットの構成

ファイル名	コア	形態論情報	セット
A01M0110	コア	手作業	1
A01M0137	コア	手作業	1
A01M0097	コア	手作業	1
A01M0056	コア	手作業	2
A03F0072	コア	手作業	2
S00M0112	コア	手作業	3
S00F0066	コア	手作業	3
S00M0213	コア	手作業	3
A04M0123	非コア	自動解析	1
A04M0121	非コア	自動解析	1
A04M0051	非コア	自動解析	1
A03M0156	非コア	自動解析	1
A03M0112	非コア	手作業	1
A03M0106	非コア	手作業	1
A05M0011	非コア	手作業	1
A02M0012	非コア	自動解析	2
A03M0016	非コア	自動解析	2
A06M0064	非コア	自動解析	2
A06F0135	非コア	自動解析	2
A01F0034	非コア	手作業	2
A01F0063	非コア	手作業	2
A01F0001	非コア	手作業	2
A01M0141	非コア	手作業	2
S00F0019	非コア	自動解析	3
S00M0079	非コア	自動解析	3
S01F0105	非コア	自動解析	3
S00F0152	非コア	手作業	3
S00M0070	非コア	手作業	3
S00M0008	非コア	手作業	3
S00F0148	非コア	手作業	3

コア： ファイルがコアに含まれるかどうか

形態論情報：形態論情報が手作業（高精度）か自動解析か（図5参照）

セット： テストセットの下位区分（詳細は asr.pdf 参照）

付録3 主要なファイルの配置とファイル名拡張子

CSJ を格納した DVD-ROM セット（第三刷）にどのような方法でファイルが記録されているかを簡単に説明する。詳細は各ディスクのルートディレクトリに置かれた README ファイル（00README.txt）を参照のこと。Disk1 の README ファイルには全体の構成が記されているので最初に参照されたい。

1) Disk1

Disk1 は以下のディレクトリ構造をもち、各種解説文書、データブラウジング用ツール、さらに個々の講演から独立したデータ類を格納している。

/DOC	本文書の表 1 に記載した解説文書類
/TOOL/XSL	XML 関係のスクリプト類
/MNFC	音声・テキストブラウザー
/XML_BROWSER	XML 検索ツール
/AM	音響モデル
/LM	言語モデル
/DATA	講演者属性データ、記録票データ、印象評定（集合評定）データなど、CSJ 全体にかかわるデータ各種
TRN/TRN-EUC	転記ファイル(EUC)*
/TRN-SJIS	転記ファイル(シフト JIS)*
/TRN-UTF8	転記ファイル(UTF-8)*
*個々の講演のディレクトリとは別にすべての転記ファイルがここにも格納されている。	
/LDB	長単位形式形態論データ**
/SDB	短単位長単位混合形式データ**
**個々の講演のディレクトリとは別にすべての形態論情報データがここにも格納されている。	
/SUWDIC	短単位辞書
/PLABEL/Xwaves	Xwaves 形式の X-JToBI ラベルデータ***
/TextGrid	Praat 用 X-JToBI ラベルデータ***
***個々の講演のディレクトリとは別にすべての X-JToBI ラベルデータがここにも格納されている。	
/CUXML	節単位 XML 文書

2) Disk2

Disk2 には XML 文書をまとめて格納している。個々の XML 文書は Disk3 以降の各講演のディレクトリにも格納されていることに注意。

3) Disk3 以降

Disk3 以降には、個々の講演に関わるデータ類を格納している。ルートディレクトリの直下に講演 ID（“A01M0001”、“S03F0099”等）を名称とするディレクトリが多数並んでいる。各ディレクトリには、すべての講演に対して提供されるファイル群が格納されている。講演 ID として“A01M0001”を例にとると以下のとおりである。

/A01M0001/A01M0001.wav （音声ファイル）*

*独話はモノラル、対話は 2 チャンネルインターリーブ

/A01M0001/A01M0001-L.wav (対話音声の左チャンネルを分離したモノラル音声)
/A01M0001/A01M0001-R.wav (対話音声の右チャンネルを分離したモノラル音声**)

**上記 2 種類のファイルは対話音声にだけ提供される

/A01M0001/A01M0001.trn (転記ファイル; シフト JIS)
/A01M0001/A01M0001.xml (XML 文書; UTF-8)
/A01M0001/A01M0001.ldf (長単位形式形態論データ)
/A01M0001/A01M0001.sdb (短単位長単位混合形式形態論データ)

ある講演がコアに含まれているか、要約・重要文抽出の対象となっていれば、講演 ID に対応するディレクトリの下に 3 個のサブディレクトリが作成されている。再び“A01M0001”を講演 ID とすると以下のとおりである。

/A01M0001/PLABEL (音声ラベルデータ・F0 データ)
/A01M0001/SUMMARY/50PER (自由要約データ、要約率 50%)
/A01M0001/SUMMARY/10PER (自由要約データ、要約率 10%)

Disk3 以降の収録内容は以下のように分類されている。

Disk3 コアに含まれる学会講演・対話・再朗読
Disk4 コアに含まれる模擬講演
Disk5 コア以外の女性による学会講演および女性による「その他 (M01～M03)」
Disk6 コア以外の男性による学会講演 (A01)
Disk7 コア以外の男性による学会講演 (A02～A03)
Disk8 コア以外の男性による学会講演 (A04～A06)
Disk9 コア以外の男性による学会講演 (A07～A10)
Disk10 コア以外の男性による学会講演 (A11～A13) および男性による「その他 (M01～M03)」
Disk11 コア以外の女性による模擬講演 (S00～S02)
Disk12 コア以外の女性による模擬講演 (S03～S06)
Disk13 コア以外の女性による模擬講演 (S07～S11)
Disk14 コア以外の男性による模擬講演 (S00～S03)
Disk15 コア以外の男性による模擬講演 (S04～S07)
Disk16 コア以外の男性による模擬講演 (S08～S11)
Disk17 コア以外の対話・朗読・再朗読

Disk1 の/ATA ディレクトリ中の talk_data.dat ファイルの「収録ディスク」フィールドには、講演 ID と収録ディスクの対応が記入されている。これによって、ある特定の講演がどのディスクに収録されているかを検索することができる (data_attribute.pdf 参照)。

以上。